

# Sistemas de Recomendación

Alejandra Gpe. Esquivel Guillén  
alejandraeg9899@gmail.com

5 de noviembre de 2015

## 1. Objetivos

Este trabajo busca esbozar las características de un sistema de recomendación, su impacto en los negocios modernos. Resaltar los algoritmos que se utilizan en su diseño. Mostraremos cómo estos sistemas obtienen las preferencias de los usuarios y presentaremos un caso de estudio donde usamos el algoritmo de vecinos cercanos.

Los sistemas de recomendación(SR) son componentes cruciales para los negocios en línea, con ellos se busca mantener a sus usuarios satisfechos e incrementar el número de ventas diarias por usuario. Por ello considero que el conocimiento de estos sistemas, son una de las tendencias más importantes de la computación de nuestro tiempo.

## 2. Introducción

Los SR aparecen a mediados los 80 de manera natural, por los vendedores que buscaban entender lo que sus clientes deseaban comprar, se generaban catálogos impresos y se entregaban con cupones dentro, en los hogares de los clientes. Con la entrada del internet y el auge del correo electrónico se inició el acercamiento usando listas de correo, muy pronto se vio la necesidad de sumar clientes o visitas de ellos al sitio web corporativo del negocio para dar variedad al catálogo. Gracias a los avances en los algoritmos de minería de datos se observó que algunas herramientas estadísticas podían usarse para anticiparse a las preferencias si conocíamos el perfil de otros usuarios con características similares. Fue así que iniciaron como simple observación de las preferencias de los clientes y en un inicio sólo se ofrecían listas de los artículos más comprados por otros usuarios de temporada. Con frecuencia los individuos confiaban en las recomendaciones ofrecidas por otros; de la misma manera que alguien te recomienda un libro o una película. La escala de evaluación comenzó en la mayoría de los productos con una escala fija (A = bueno, B = regular, C = malo) en donde se establece el valor de cierta variable (calidad, precio, disponibilidad). Los sistemas de recomendación hoy en día juegan un rol importante en todos los sitios web. La meta de ellos es incrementar las ventas, visitas, variedad de contenidos y presentar experiencias de usuario personalizadas ofreciendo sugerencias para artículos desconocidos potencialmente interesantes para un usuario.

Los SR actuales utilizan algoritmos avanzados y se invierten grandes recursos en su desarrollo.

El interés en esta área permanece alto debido a que constituye un problema rico en investigación y a la abundancia de aplicaciones prácticas que ayuden a los usuarios a lidiar con sobrecarga de información.

Las grandes compañías de medios fueron las primeras en invertir en SR. En 2006 Netflix lanzó una competencia para mejorar su entonces sistema de recomendación en al menos un 10 % de efectividad.

El rol clave de los sistemas de recomendación es que se basan en minería de datos, rama de la computación que se encuentra en auge y que utiliza algoritmos de inteligencia artificial obteniendo conocimiento a partir de la información.

Sin embargo, a pesar de todos estos avances, la actual generación de sistemas de recomendación evoluciona rápidamente presentando retos imposibles de resolver por la arquitectura computacional requerida como consecuencia esto a llevado a una competencia entre las empresas por vender la 'mejor solución'. Lo que se busca al diseñar un SR es que se adapte a la inmensa cantidad de información generada por los usuarios optimizando la memoria requerida. Los SR se aplican a un rango amplio de casos como recomendaciones vacacionales, ciertos tipos de servicios bancarios o de financiamiento a inversionistas, y productos a ser vendidos en una tienda creada por un 'carrito inteligente'. Estas mejoras incluyen mejores métodos para representar comportamiento y la información acerca de los artículos ha ser adquiridos, métodos avanzados de recomendación, incorporación de información contextual y utilización de ratings multicriterio, además del desarrollo de métodos menos intrusivos que también se apoyan en métricas para determinar desempeño de los sistemas de recomendación.

- La recolección de preferencias de los usuarios: **No tiene nada que ver con los perfiles de usuario** ya que esto se realiza a través de una en-

cuesta que permite conocer las preferencias de los usuarios, algunos de ellos mencionan las características deseables de un artículo específico.

- **Análisis: En esta etapa se detectan patrones en las opciones seleccionadas por los usuarios. -**
- **Generación de opciones:** Los SR se modifican continuamente debido a que el usuario interactúa con el catálogo de artículos y el SR debe adaptarse dinámicamente a dichos cambios.
- **Artículos Recomendados:** Los artículos pueden ser en general cualquier bien o servicio requerido por un usuario específico. No se requiere que el usuario tenga experiencia previa con el uso del sistema principal. Sin embargo sus selecciones son tomadas en cuenta para mejorar la precisión de la recomendación próxima.

## 2.1. Características clave que un SR debería cumplir

- **Incrementar el número de artículos vendidos:** Debería ser capaz de vender un conjunto de artículos de modo que puedan ser comprados sin la intervención de los SR, es decir puede tener su propia meta de venta (\*\*ningún visitante se puede ir sin comprar \*\*).
- **Vender artículos diversos:** Se prefiere la diversidad de artículos al ofertar productos ya que las empresas buscan que los usuarios (clientes) detecten productos en los que ni siquiera han pensado adquirir. Con frecuencia se dan descuentos o rebajas en ellos lo que ocasiona que las recomendaciones de los usuarios impacten su venta.
- **Incrementar la satisfacción del usuario:** Un SR bien diseñado cambia la interfaz de usuario según las preferencias de los mejores clientes, ofreciendo objetivos resaltados y posibilidad de que en base a los cambios de la interfase se crean grupos de interés para ofertar productos.
- **Mejor entendimiento de lo que el usuario quiere:** El sondeo adecuado de las preferencias del usuario, permite afinar los parámetros del SR con el fin de acertar en el “mejor” producto.
- **Incrementar la fidelidad del usuario:** La interacción por parte del usuario con el sitio permite que la información sea dinámica (contenido que mantenga la atención) con frecuencias las sugerencias y reseñas de un producto mantienen al usuario mas tiempo en el sitio lo que se aprovecha dando mas opciones de compra.

## 2.2. Clasificación de los SR

Los SR usualmente son clasificados en las siguientes categorías:

- **Recomendaciones Basadas en contenido:** Al usuario le serían recomendados artículos similares a los que selecciona en el pasado.
- **Recomendaciones Colaborativas:** Al usuario le serían recomendados artículos que gustan a las personas con preferencias y gustos similares en el pasado.

- **Aproximación Híbrida:** Estos métodos combinan métodos colaborativos y basados en contenido.

Adicionalmente los sistemas de recomendación que predicen valores absolutos de rating que usuarios individualmente no han marcado aun en artículos no conocidos, se les conoce como *filtrado basado en preferencias* .

### 3. Importancia de los SR

El interés de las empresas y universidades en las SR se basa en que constituye un problema rico en investigación debido las aplicaciones prácticas que ayuden a los usuarios a lidiar con sobrecarga de información y el beneficio económico que se puede obtener de ellas.

Las grandes compañías de medios fueron las primeras en invertir en máquinas de aprendizaje comerciales. En 2006 Netflix anunció su máquina de aprendizaje y la competencia de minería de datos Netflix Prize con 1 millón de dólares para el equipo que logrará mejorar su entonces recomendador, el cual fue reclamado en 2009, con toda la atención de los medios, lo que se conoció como ‘Recomendaciones de Netflix: Más allá de las 5 estrellas’, reveló que la ciencia de los datos (Science Data) puede ser una grán inversión para cualquier negocio en línea y que la ciencias de la computación en la rama de aprendizaje automático, tiene algoritmos que pueden ser adaptados sistema comercial. La meta de Netflix Prize fue fundear un algoritmo de recomendaciones que pudiera entregar 10 % de mejora en precisión de predicción sobre el sistema existente para ello utilizaron herramientas conocidas como Deep Learning. Apple basa su sistema de recomendaciones de estrenos en el sistema de crítica Rotten Tomatoes. Google Play Store en un sistema de ranking de aplicaciones.

El rol clave de los sistemas de recomendación resulta en una vasta cantidad de investigación en este campo

Sin embargo, a pesar de todos estos avances, la actual generación de sistemas de recomendación aún requieren mejoras para realizar métodos más efectivos y aplicables a un rango amplio de casos como recomendaciones vacacionales, ciertos tipos de servicios bancarios o de financiamiento a inversionistas, y productos a ser vendidos en una tienda creada por un “carrito inteligente”. Estas mejoras incluyen métodos para representar comportamiento de los usuarios y la información acerca de los artículos van ser adquiridos, métodos avanzados de recomendación, incorporación de información contextual (Ubicación Geográfica, Usuarios satisfechos del producto, etc) y utilización de ratings multicriterio. Además del desarrollo de métodos no intrusivos que también se apoyan en métricas para determinar desempeño de los sistemas de recomendación.

## 4. Antecedentes

Las raíces de los sistemas de recomendación inician con trabajos en ciencia cognitiva, recuperación de información y algunas conexiones con administración científica, emergen como un área independiente a mediados de 1990 cuando los investigadores se enfocan en problemas de recomendación que explícitamente se basaban en una estructura de rating. Intuitivamente, esta estimación es usualmente basada en la escala definida por un usuario acerca de una breve información. A partir del rating de algunos artículos se puede determinar el rating de algunos que no han sido seleccionados, con el **rating superior estimado**. De manera formal el problema de recomendación puede ser formulado como sigue: Sea  $C$  el conjunto de todos los usuarios y sea  $S$  el conjunto de los posibles artículos que pueden ser recomendados tales como libros, películas o restaurantes. El espacio  $S$  de los posibles artículos puede ser muy amplio, alcanzando los cientos de millones de artículos. Similarmente el espacio del usuario puede ser bastante amplio. Sea  $u$  la función de utilidad que mide el beneficio de un artículo  $s$  al usuario. De modo que  $C \times S \rightarrow R$ , donde  $R$  es la totalidad de un conjunto ordenado. Entonces, para cada usuario  $c \in C$ , queremos seleccionar tal  $s' \in S$  que maximiza la utilidad del usuario. De manera simplificada tenemos que:  $\forall c \in C, s' = \operatorname{argmax}_u(c, s)$

En un sistema de recomendación la utilidad de un artículo es usualmente representada por un *rating* el cual indica como a un usuario particular le gusta un artículo en particular. Juan Perez le dio a “Harry Potter” el rating de 7 (en escala de 1 a 10).

**Ratings.** Rotten Tomatoes (Tomatómetro): El rating del tomatómetro se basa en las opciones publicadas por críticos de cine y televisión, es una medida confiable de la calidad de una película y representa el porcentaje de reseñas positivas dadas a una película,

**Filtrado Colaborativo:** La idea detrás del filtrado colaborativo es que se pueden usar los rating de los usuarios que comparten gustos similares para predecir los que aún no han sido definidos. Para obtener intuición, se comparan los ratings por pares del usuario

### 4.1. Ejemplos de SR:

- Airbnb. Sitio de recomendación de hospedaje. Promueve el hospedaje en casas o departamentos de particulares que ofrecen habitaciones a bajo precio donde además de mostrar ubicaciones disponibles por fecha y ubicación preferida, se incluye información de reseñas de clientes previos y se mezclan con comentarios de redes sociales relacionadas al perfil del usuario.
- Yelp. Recomendación de restaurantes. Los usuarios publican reseñas de sitios como: Restaurantes, Tiendas, Servicios (Taxi, Tintorería, Lavandería) y van construyendo confianza en los proveedores o vendedores de cierto bien, después se publican en un portal donde se localizan ubicándolos por ubicación cercana al cliente.
- Los SR de grandes empresas como Google Play, Apple Movies utilizan un sistema de ranking para sugerir aplicaciones. Un sistema de ranking puede utilizar elementos como el número de descargas, el tamaño de la aplicación,

y la ubicación geográfica del vendedor para mostrar en primer lugar las aplicaciones que tienen la misma categoría y que han sido seleccionadas por otros usuarios en compras previas. De manera similar al ranking de las búsquedas de google, se cuentan las palabras clave (keywords) y el número de links a un sitio específico. De ahí que sólo se muestran los primeros 10 sitios más visitados.

## 5. Descripción del Problema

Se consideraá una empresa dedicada a la venta y renta de inmuebles cuyos canales de venta són entrevistas y mediante llamadas telefónicas. Ha decidido invertir en un sitio web donde publica el listado de propiedades a ofertar. Como en la mayoría de sitios web el diseño se centra unicamente en ser un portal informativo. Con frecuencia buscando llamar la atención del usuario se utilizan elementos dinámicos basados en imágenes o videos, de tal manera que no es posible identificar información relevante o es imposible realizar una búsqueda en texto para localizar un artículo específico. Por consecuencia los clientes que visitan el sitio (ver info de visitas) observan que resulta muy complicado localizar alguna propiedad relevante, o simplemente toma demasiado tiempo navegar pagina a página para encontrar lo que se requiere.

Este ejemplo es el caso de la mayoría de negocios mexicanos que utilizan un portal web para anunciarse y no aprovechan la interacción con sus clientes. Dentro de la ciudad de Morelia, se han detectado poco más de 30 inmobiliarias que utilizan portales para promoción, incluso las principales constructoras (Arko, Habicasa) utilizan portales de tipo informativo. Este proyecto busca incrementar la cantidad de información que un usuario promedio recibe al consultar una propiedad. Para ello se incluyen sugerencias de propiedades similares con el fin de mantener el usuario más tiempo en sitio y por consecuencia incrementar la utilidad de la información. Adicionalmente para mejorar las recomendaciones, durante la navegación se buscará conocer las preferencias del usuario utilizando breves cuestionarios sobre la información que se está consultando para identificar potenciales opciones.

### 5.1. Metodología

Nuestra propuesta de diseño se centra en 4 puntos.

1. Recolección de Datos.
2. Filtrado y Clasificación de los datos.
3. Proporcionar recomendaciones cercanas a las seleccionadas por el usuario.
4. Retroalimentación a través de encuestas de satisfacción al cliente.

### 5.2. Recolección de los datos

Para la recolección, seleccionamos 20 inmobiliarias de la ciudad de morelia, algunos portales no presentaban listados accesibles y las descartamos. Del conjunto que era posible consultar propiedades a traves de una url directa se decidió utilizar un crawler público[6] que nos permitiera indexar las paginas web de las inmobiliarias, de ahí obtenemos una lista de links ??, filtramos la lista dejando unicamente las que se refieren a propiedades y almacenamos los documentos en formato HTML.

### 5.3. Filtrado y Clasificación

Extraemos el cuerpo principal de los documento usando el lenguaje de programación python y almacenamos cada propiedad en un nuevo conjunto de



datos que convertiremos a un archivo csv para posteriormente realizar la clasificación de las propiedades. Es importante destacar que no se requiere almacenar en una base de datos relacional debido simplifica el realizar el análisis usando únicamente archivos en texto plano.

100 Internal links XLS   HTML						
▲ ▼	URL of pages being spidered	OPR	LFHA ▼	Status ▲ ▼	IL ▲ ▼	Link text
1	www.mirainmobiliaria.mx/?gclid=Cj0KEQjwtaex...	Run	0	200	0	start
2	www.mirainmobiliaria.mx/inmuebles/busqueda/	Run	1	200	2	Búsqueda avanzada
3	www.mirainmobiliaria.mx/	Run	1	200	3	image file (alt text: "http://www.m
4	www.mirainmobiliaria.mx/themes/v3-shop-001/	Run	1	404	5	image file (alt text: "Español")
5	www.mirainmobiliaria.mx/engb/?gclid=Cj0KEQj...	Run	1	200	1	image file (alt text: "English")
6	www.mirainmobiliaria.mx/inmuebles/	Run	1	200	5	Inmuebles
7	www.mirainmobiliaria.mx/comparar/	Run	1	200	7	Comparar
8	www.mirainmobiliaria.mx/promociones/	Run	1	200	7	Desarrollos
9	www.mirainmobiliaria.mx/agencia/procuo/	Run	1	200	8	Busco un Inmueble
10	www.mirainmobiliaria.mx/agencia/oferta/	Run	1	200	10	Oferta de Inmueble
11	www.mirainmobiliaria.mx/contactos/	Run	1	200	10	Contactos
12	www.mirainmobiliaria.mx/inmueble/679320/ca...	Run	1	200	2	CASA EN VENTA FRACCIONAMIENT
13	www.mirainmobiliaria.mx/inmueble/2576048/s...	Run	1	200	1	SE VENDE HERMOSA CASA EN COL
14	www.mirainmobiliaria.mx/inmueble/624284/est...	Run	1	200	2	ESTRENA CASA DE TRES RECÁMAR
15	www.mirainmobiliaria.mx/inmueble/867128/ca...	Run	1	200	1	CASAS DESDE \$1,544,000 A \$2,31
16	www.mirainmobiliaria.mx/inmueble/1188667/s...	Run	1	200	1	SE VENDE CASA DE 1 PLANTA EN V
17	www.mirainmobiliaria.mx/inmueble/819390/res...	Run	1	200	1	image file (alt text: "")
18	www.mirainmobiliaria.mx/inmueble/699184/ca...	Run	1	200	1	image file (alt text: "")
19	www.mirainmobiliaria.mx/inmueble/745911/ca...	Run	1	200	1	image file (alt text: "")
20	www.mirainmobiliaria.mx/promocion/2931755/...	Run	1	200	4	image file (alt text: "Frac. Las Acac
21	www.mirainmobiliaria.mx/promocion/2931533/...	Run	1	200	4	image file (alt text: "Frac. Villas del
22	www.mirainmobiliaria.mx/promocion/2065541/...	Run	1	200	4	image file (alt text: "Rincón del Cie
23	www.mirainmobiliaria.mx/promocion/2931135/...	Run	1	200	3	image file (alt text: "Monteviento, T

Figura 1: Listado de Artículos relacionados con propiedades




Figura 2: Distribución de Propiedades Tipo de Propiedad

## 5.4. Clasificación de las propiedades

Para el procesamiento de los datos crudos decidimos utilizar el lenguaje de programación R, para analizar y clasificar. Las propiedades que descargamos de los portales web las hemos agrupado en un solo listado con aproximadamente 284 registros, las cuales vienen listadas por Estado de la propiedades (Usado, Nuevo, Construcción), Área construida ( $m^2$ ), Zona (Colonia o barrio de Referencia), Precio, Latitud, Longitud y algunas otras características como el tipo de propiedad (ver ??).

El algoritmo de clasificación para esta sección que hemos seleccionado es el de vecinos cercanos (KNN) ya que estamos trabajando con variables categóricas,

	Total
Bodega	5
Casa	168
Departamento	24
Edificio	1
Local	13
Oficinas	1
Terreno	72

Figura 3: Tabla de Propiedades por Inmueble

nuestro objetivo es ofrecer opciones con características similares dentro de cada categoría correspondiente.

Latitud	Estado	Superficie Uti
19.66721110000	Nuevo	60
19.67036430000	Usado	199.36
19.6599095000%	No Aplicable	360
19.60531230000	No Aplicable	1.25 ha
19.65956219969	Usado	140
19.56690721050	No Aplicable	160
19.73287613516	Nuevo	151
19.67198296710	Nuevo	118
19.70408386499	Usado	350
19.70945930000	Usado	110

Figura 4: Dataset de Propiedades Inmobiliarias

## 5.5. KNN - Nearest Neighbor

También conocido como K-nearest Neighbor es el más simple de los algoritmos de aprendizaje máquina que existe y el más utilizado si se trabaja con variables categóricas. Se basa en identificar los k registros en el conjunto de entrenamiento que son *cercanos* en similitud. La prueba asigna una clase a la mayoría de los vecinos cercanos similares. El KNN trata las características como coordenadas multidimensionales. Después tomaremos una o más registros conjunto de prueba, los cuales serán las selecciones del usuario.

## 5.6. Métrica de similitud con distancia.

El KNN requiere una función distancia, o una métrica que mida la similitud entre dos instancias. Existen diferentes maneras de calcular la distancia. Tradicionalmente el Knn utiliza la distancia euclídeana, que es la distancia de un punto con respecto a otro conectados por una línea recta. La distancia euclídeana se expresa de la siguiente manera:

$$dist(x, y) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \dots + (p_n - q_n)^2} \quad (1)$$

El KNN requiere elegir una cantidad vecinos cercanos (K) y determinar que tan bien el modelo clasifica nuevos valores. El balance entre sobre ajustar o subajustar el valor de K para el conjunto de entrenamiento es un problema

conocido como **ajuste de la varianza**. Seleccionando valores de  $K$  reduce el impacto de la varianza causada por datos ruidosos, pero puede que el sistema ignore los grupos pequeños, incluyendolos equivocadamente en una clase. En el lado opuesto usando una  $K$  mayor se influye sobre la muestra clasificada. Por prueba y error, el mejor valor de  $k$  se encuentra entre estos dos extremos cuando las sugerencias mostradas son más parecidas entre si.




Figura 5: Efectos de seleccionar diferentes valores de la  $K$  en KNN

## 6. Resultados

De la figura 4 podemos analizar que de una entrada dada de 40 selecciones se puede sugerir un conjunto de propiedades con una K de 7 probamos distintos valores de K para refinar la consulta y obtener resultados con características similares a la entrada de datos. Sin embargo al utilizar este algoritmo utilizamos una función de normalización de los datos buscando que las propiedades consideradas en la misma escala, se afecta el resultado del clasificador.

Casas_test_labels	Casas_test_pred				Row Total
	Casa	Departamento	Local	Terreno	
Bodega	0	0	1	0	1
	0.000	0.000	1.000	0.000	0.012
	0.000	0.000	0.250	0.000	
	0.000	0.000	0.012	0.000	
Casa	36	4	0	8	48
	0.750	0.083	0.000	0.167	0.571
	0.837	0.500	0.000	0.276	
	0.429	0.048	0.000	0.095	
Departamento	2	1	1	0	4
	0.500	0.250	0.250	0.000	0.048
	0.047	0.125	0.250	0.000	
	0.024	0.012	0.012	0.000	
Local	0	3	1	0	4
	0.000	0.750	0.250	0.000	0.048
	0.000	0.375	0.250	0.000	
	0.000	0.036	0.012	0.000	
Oficinas	0	0	1	0	1
	0.000	0.000	1.000	0.000	0.012
	0.000	0.000	0.250	0.000	
	0.000	0.000	0.012	0.000	
Terreno	5	0	0	21	26
	0.192	0.000	0.000	0.808	0.310
	0.116	0.000	0.000	0.724	
	0.060	0.000	0.000	0.250	
Column Total	43	8	4	29	84
	0.512	0.095	0.048	0.345	

Figura 6: Propiedades recomendadas según la selección del Usuario

## 7. Bibliografia

- [1] Adomavicius, G., and A. Tuzhilin. “Toward the next Generation of Recommender Systems: A Survey of the State-of-the-art and Possible Extensions.” *IEEE Trans. Knowl. Data Eng. IEEE Transactions on Knowledge and Data Engineering*: 734-49. Print.
- [2] Sauter, Vicki Lynn, and Vicki Lynn Sauter. *Decision Support Systems for Business Intelligence*. 2nd ed. Hoboken, N.J.: Wiley, 2010. Print.
- [3] R.Bell, Y. Koren and C. Volinsky. *The BellKor 2008 Solution to the Netflix Prize*. 2008
- [4] Said, Alan, Brijnesh J. Jain, Sascha Narr, and Till Plumbaum. “Users and Noise: The Magic Barrier of Recommender Systems.” *User Modeling, Adaptation, and Personalization Lecture Notes in Computer Science*: 237-48. Print
- [5] Lantz, B. (n.d.). *Machine learning with R: Learn how to use R to apply powerful machine learning methods and gain an insight into real-world applications*.
- [6] Harrington, P. (2012). *Machine learning in action*. Shelter Island, NY: Manning Publications.
- [7] Toomey, D. (n.d.). *R for data science*.
- [8] Teutonico, D. (2015). *Ggplot2 essentials explore the full range of ggplot2 plotting capabilities to create meaningful and spectacular graphs*. Birmingham, England: Packt Publishing.
- [9] Leipzig, J., & Li, X. (2009). *Data mashups in R*. Sebastopol, Calif.: O'Reilly.
- [10] Ricci, F. (2011). *Recommender systems handbook*. New York: Springer.
- [11] Russell, S., & Norvig, P. (1995). *Artificial intelligence: A modern approach*. Englewood Cliffs, N.J.: Prentice Hall.
- [12] Website Crawler Tool and Google Sitemap Generator  
<http://freetools.webmasterworld.com/tools/crawler-google-sitemap-generator/>